

# Proyecto Final Parte III

Ursula Macedo

# Indice

• 01 | Introducción

• 02 | Hipotesis

• 03 | Datos

• 04 | Modelo

• 05 | Conclusion

## Introducción

Analizar la demanda de energía eléctrica permite detectar tendencias y estacionalidades. Esta información es muy útil para gestionar la demanda de manera eficiente, prever picos de consumo y planificar en consecuencia reduciendo riesgos de desabastecimiento.

Los sectores industriales y comerciales suelen concentrar su actividad en los días hábiles, incrementando su demanda durante las horas pico (18 a 22 Hs). La planificación y asignación de los recursos energéticos pueden verse afectadas si la demanda en picos no se gestiona correctamente entre días hábiles y no hábiles y puede generar sobrecostos por generación innecesaria o incluso riesgos de corte de suministro.

## Hipótesis

Probabilidad de que una provincia experimente alta demanda en horas pico (18 a 22 hs) depende del tipo de día (hábil o no hábil)


# Datos

Se seleccionó un dataframe que contiene datos de demanda de energía eléctrica de Argentina desde el año 2022 hasta febrero de 2025, los mismos provienen de la página de CAMMESA (organismo encargado de operar el mercado eléctrico mayorista de Argentina). Sus columnas contienen los siguientes datos:

- Año: año de demanda
- mes: mes de demanda, formato mes-año
- nummes
- numdía
- Tipodedía: hábil, no hábil
- día: Día de la semana
- fecha: formato día/mes/año
- hora
- GUMEM: Demanda de grandes usuarios en MWh, la misma está compuesta por la demanda de la categoría GUMA (Gran Usuario Mayorista Autogenerador) como ejemplo se pueden mencionar las demandas de las empresas Arcor, Acindar, aysa, molinos cañuelas, ypf entre otras.
- Distribuidor: La categoría distribuidor comprende la demanda en MWh de la demanda estacional y las GUMEs (Grandes Usuarios Menores) como ejemplo se pueden mencionar cooperativas, Edelap, Edenor, Edesur, EPEC entre otros.
- DEMANDALOCAL: La demanda local es la suma de las demandas GUMEM y Distribuidor
- Demanda en MWh de las siguientes provincias:  
BUENOSAIREs,CATAMARCA,CHACO,CHUBUT,CORDOBA,CORRIENTES,ENTRERIOS,FORMOSA,JUJUY,L  
APAMPA,LARIOJA,MENDOZA,MISIONES,NEUQUEN,RIONEGRO,SALTA,SANJUAN,SANLUIS  
SANTACRUZ,SANTAFE,SGODELESTERO,TUCUMAN

# EDA **DATA ANALYSIS**

# Datos




# Datos

Variable target: altademanda= 1, bajademanda=0

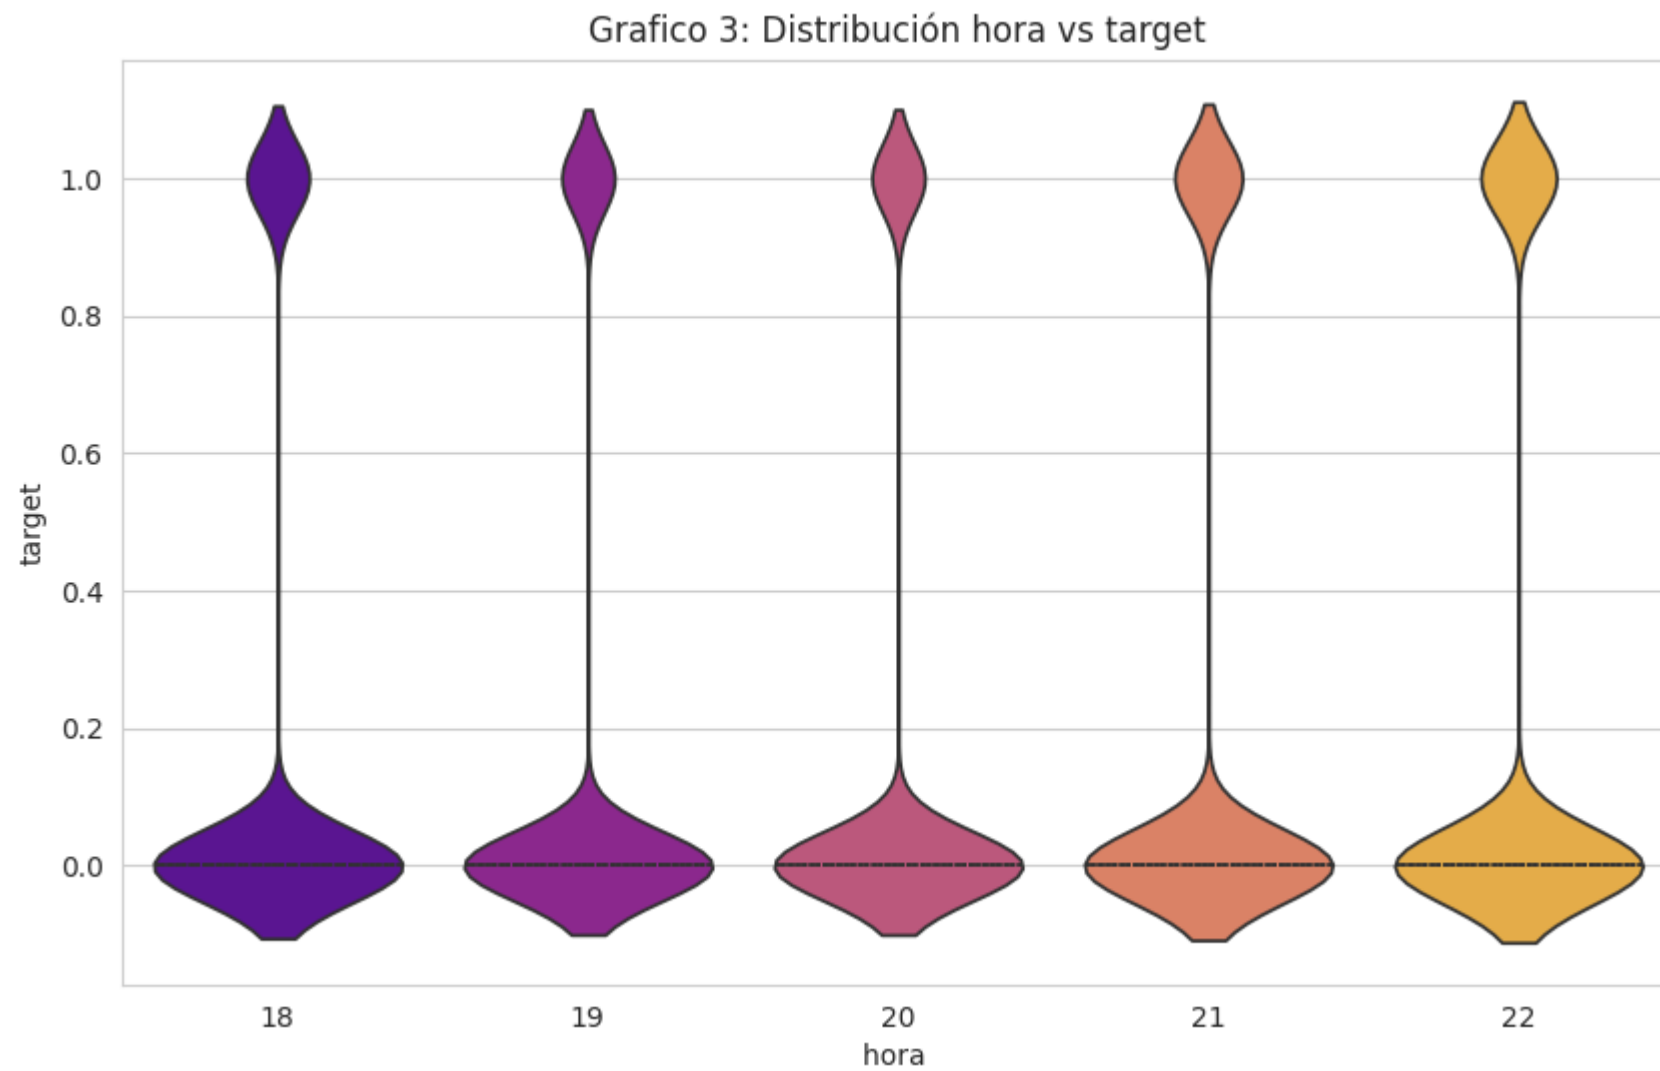
.

Grafico2: Distribución de Variable target (altademanda= 1, bajademanda=0)





Datos

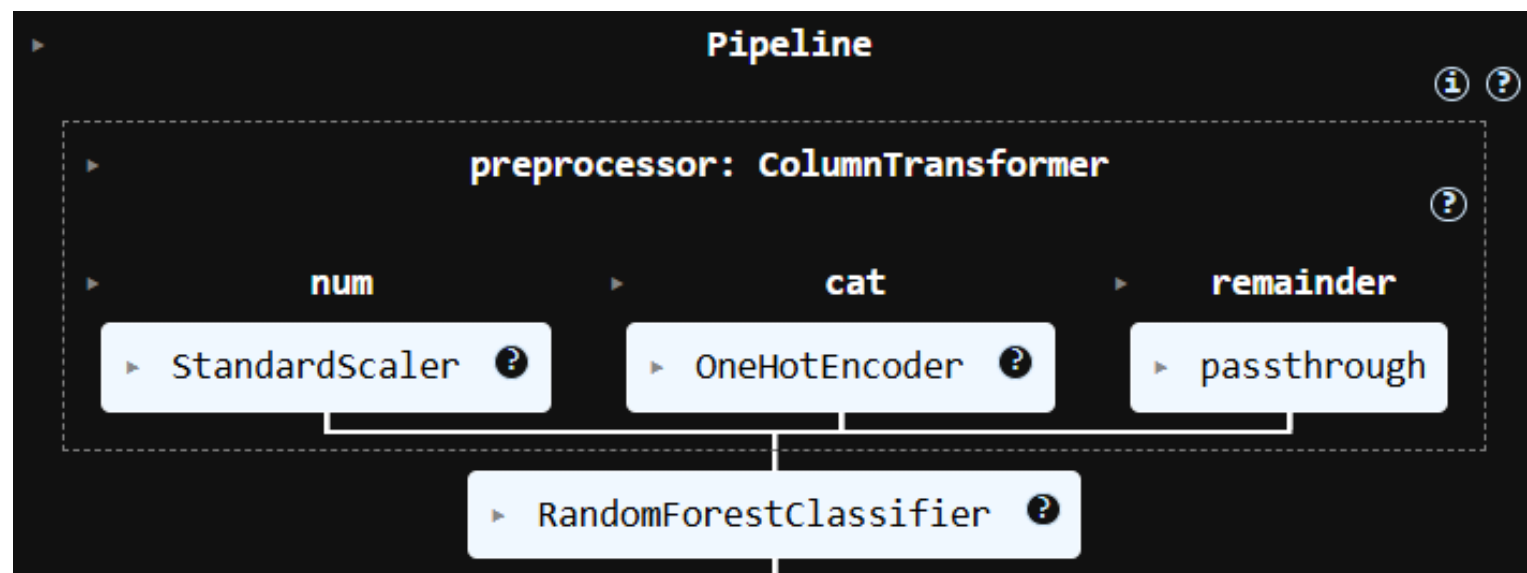


# MODELO

# Modelo

## Random Forest Classifier

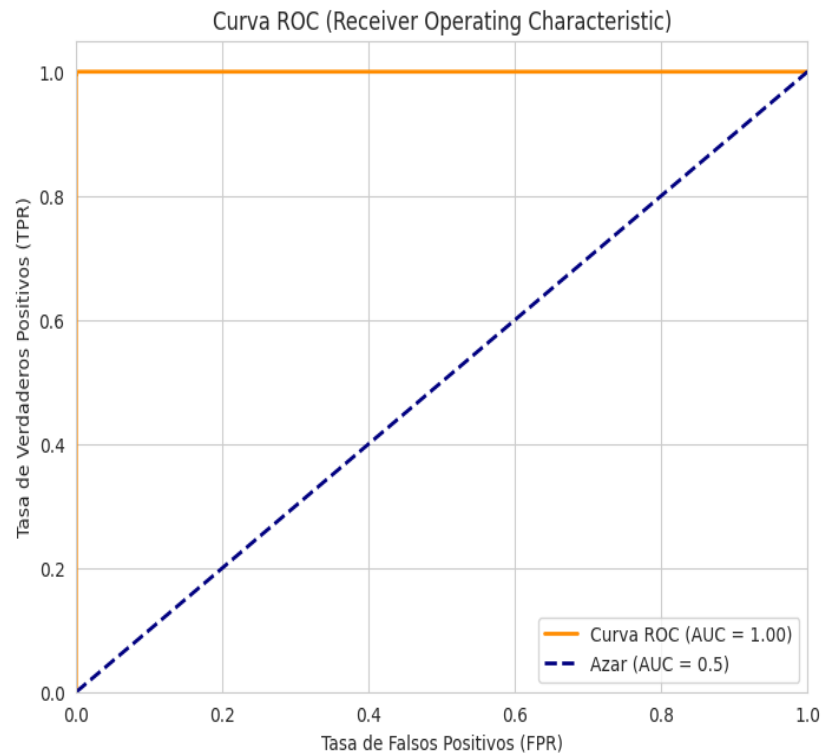

.



# Modelo

## Random Forest Classifier

•



Random Forest Classifier:

Accuracy del modelo en el conjunto de prueba: 0.9991

AUC del modelo en el conjunto de prueba: 1.0000 Recall y F1-Score para ambas clases (0 y 1).

## Conclusion

Obtuvimos una Accuracy de 1.00 y un AUC de 1.00. Con el accuracy se puede indicar que el modelo separa bien la alta y baja demanda. Sin embargo, esto puede significar overfitting. Las métricas de precisión pueden sugerir que no hay problemas de desbalance en la predicción ya que se utilizó `class_weight='balanced'` en el modelo. La variable tipo de día (hábil o no hábil) influye en la probabilidad de alta demanda, pero no tanto como la propia demanda.